



---

## Classification de la végétation péri-urbaine ou forestière, haute, par télédétection LIDAR et hyperspectrale

---

Amrari Sélim

Supervisé par: Matthew Parkan



**Abstract:** La facilité d'accès des données aéroportées laisse aujourd'hui envisager l'application de méthodes de télédétection/classification de la végétation en milieux urbains et péri-urbains. A cette fin, une méthode de classification tirant parti de la complémentarité de données LIDAR et hyperspectrales a été expérimentée dans plusieurs configurations d'ajustement.

Friday 16<sup>th</sup> June, 2017

# Table des matières

|          |                                                          |           |
|----------|----------------------------------------------------------|-----------|
| <b>1</b> | <b>Introduction</b>                                      | <b>3</b>  |
| <b>2</b> | <b>Données et sites d'étude</b>                          | <b>5</b>  |
| 2.1      | Régions d'étude . . . . .                                | 5         |
| 2.2      | Données . . . . .                                        | 6         |
| 2.3      | Échelles d'étude et ensembles d'entraînement . . . . .   | 8         |
| <b>3</b> | <b>Méthodologie</b>                                      | <b>11</b> |
| 3.1      | Compromis entre biais et variance . . . . .              | 11        |
| 3.2      | Définition des descripteurs . . . . .                    | 12        |
| 3.3      | Pré-traitements des données . . . . .                    | 15        |
| 3.4      | Classification : Machine à vecteurs de support . . . . . | 17        |
| 3.5      | Sélection du modèle . . . . .                            | 22        |
| <b>4</b> | <b>Résultats</b>                                         | <b>25</b> |
| 4.1      | Ensemble d'entraînement 1 . . . . .                      | 25        |
| 4.2      | Ensemble d'entraînement 2 . . . . .                      | 31        |
| <b>5</b> | <b>Conclusion</b>                                        | <b>36</b> |
| <b>6</b> | <b>ANNEXE</b>                                            | <b>40</b> |

# 1 Introduction

La disponibilité accrue, depuis quelques années, des données aéroportées LIDAR et hyperspectrales laisse envisager des méthodes de classification et de recensement du couvert végétal en milieu péri-urbain par télédétection. Ces approches offrent un avantage en terme d'efficacité par rapport à des mesures de terrain, puisqu'elles apportent la possibilité de traiter des données à l'échelle de larges surfaces.

Il existe aujourd'hui une multitude d'approches pour aborder le sujet de la classification de la végétation. En premier lieu, il est nécessaire de classer la couverture ou l'utilisation du sol en elle même. Cela permet de localiser les surfaces de végétation ainsi que leurs stades d'évolutions. Certains travaux abordent cette tâche grâce à l'information spectrale uniquement [1]. D'autres se fondent sur la structure des données LIDAR, plus précises spatialement, pour classer l'environnement urbain et péri-urbain [2] [3]. Certaines techniques évaluent aussi bien la texture des images aéroportées que la structure des nuages de points et peuvent être utilisées pour classer les surfaces [4]. En plus, d'apporter une information spatiale précise, permettant la localisation de la végétation, les échos LIDAR peuvent également permettre l'élaboration de modèles d'ombrage [5]. L'ombrage d'une surface est responsable d'une variation de la réflectance enregistrée par les capteurs spectraux. Ces modèles peuvent offrir une correction à cet effet. Vient alors la tâche de classification qui induit la sélection de descripteurs pertinents. Lors de l'utilisation de descripteurs spectraux, ceux-ci peuvent prendre la forme d'indices élaborés sur la base de connaissances acquises ou être directement sélectionnés parmi les réflectances [6] [7]. L'analyse en composantes principales est souvent utilisée afin d'extraire une sélection de descripteurs décorrélés [6] [8]. Certaines méthodes de classification telles que les régressions de Lasso, qui génèrent des solutions partiellement nulles [9], ou les forêts d'arbres décisionnels [3] peuvent aussi servir à cette sélection. En outre, ces descripteurs peuvent être engendrés par des échos LIDAR. En ce cas, ils permettent de décrire efficacement la morphologie de la végétation [10]. Enfin les choix du type de classifieur et de ses configurations sont très larges. De nombreuses études se focalisent sur l'emploi de forêts d'arbres décisionnels, classifieur qui gèrent aisément de large ensembles de données [2]. Les machines à vecteurs de support sont également très employées. Étant convexes, elles ont l'avantage de ne converger que vers un optimum globale lorsque la solution existe et leurs nombreuses configurations bénéficient de l'utilisation de noyaux algébriques [11]. Finalement, les systèmes de réseaux de neurones sont aujourd'hui de plus en plus répandus [12]. L'augmentation des puissances de calcul facilite leur utilisation.

L'utilisation conjointe de données LIDAR et hyperspectrales amène une complémentarité utile aux milieux urbains. La donnée hyperspectrale apporte une forte quantité d'informations grâce à sa très fine résolution spectrale qui permet la reconstitution de signatures optiques. Cependant la présence de différents types de surfaces sur l'image (bitumes, voitures...) produit des pixels aux réflectances composites qui doivent être démêlées pour extraire des signatures spectrales pures. La donnée LIDAR après traitement du nuage de points permet de localiser précisément les parcelles de végétation, suffisamment hautes et denses pour être observées sur une image aéroportée. A l'information spectrale des images aéroportées s'ajoute donc l'information spatiale du nuage de points LIDAR. Il est alors en théorie possible d'extraire les pixels dont la réflectance est issue d'un seul arbre qu'il est alors possible de classer en tant qu'individu.

Toutefois, les méthodes de classification ont leur difficultés. Elles nécessitent une forte quantité de données exploitables afin d'entraîner convenablement chaque modèle [13]. Chaque classe de végétation doit être suffisamment représentée au sein des données pour pouvoir décrire les caractères qui l'identifient. Aussi, adopter comme descripteurs la totalité des bandes spectrales d'une images renforce d'autant plus ce besoin d'un plus large échantillon de données. Le non respect de ces critères engendre le risque de modèles de classification sur-ajustés, dans le cas d'un trop grand nombre de descripteurs, ou biaisés, dans le cas d'un ensemble de données trop restreint.

L'objectif de ce projet est d'identifier les arbres appartenant à la végétation haute en fonction de leur genre et de leur espèce. Ce travail propose d'évaluer les performances d'un classifieur à vecteurs de support, employé sur deux ensembles de données. Ces deux ensembles sont extraits à l'aide de méthodes distinctes et se composent d'observations produites à deux échelles différentes. Il s'agira également d'évaluer la complémentarité de descripteurs morphologiques et spectraux, produits grâce à l'apport conjoint de l'imagerie et du LIDAR aéroportés.

## 2 Données et sites d'étude

### 2.1 Régions d'étude

Ce travail est réalisé à l'aide de données acquises dans le canton de Vaud ainsi que dans le canton de Neuchâtel. Les sites d'étude utilisés se situent dans le voisinage direct des villes de Lausanne et Neuchâtel. Certaines données proviennent de milieux péri-urbains comme la forêt de Sauvabelin mais l'essentiel des échantillons sont issus de milieux forestier.



**FIGURE 1** – Site d'étude de la forêt de Sauvabelin à Lausanne. Sont visibles en vert les localisations de données dendrométriques issus de relevés de terrains et d'interprétations directes des échos LIDAR. (Image acquise par le système APEX, produite par les bandes spectrales 58, 16, 4, de longueur d'onde 0.7008, 0.55182, 0.45018 [ $\mu\text{m}$ ])

## 2.2 Données

### Données hyperspectrales :

Des orthophotos hyperspectrales ont été acquises le 18 juillet 2014. Celles-ci ont été produites grâce au système APEX. Une correction des effets atmosphériques a été effectuée préalablement à ce travail (voir [14], [15]). La résolution au sol des orthophotos utilisées lors de ce travail est de 2.62 mètres.

**TABLE 1** – Spécification du système Apex

| Intervalle spectral       |                                         |
|---------------------------|-----------------------------------------|
| Proche infrarouge visible | 380 – 970 nm                            |
| Infrarouge, ondes courtes | 940 – 2500 nm                           |
| Résolution spectrale      |                                         |
| Proche infrarouge visible | 0.6 – 6.3 nm                            |
| Infrarouge, ondes courtes | 6.2 – 11 nm                             |
| Taille des pixels         |                                         |
| Proche infrarouge visible | 22.5 $\mu\text{m}$ x 22.5 $\mu\text{m}$ |
| Infrarouge, ondes courtes | 30 $\mu\text{m}$ x 30 $\mu\text{m}$     |

**TABLE 2** – Structure utilisée des nuages de points (.LAS)

| Attributs       | Description                                                                                                |
|-----------------|------------------------------------------------------------------------------------------------------------|
| X,Y,Z           | coordonnées du point en système de coord. CH1903                                                           |
| Label de classe | classe des échos en fonction du type de couverture<br>(exemple : sol nu, sol imperméable, végétation, eau) |

**Données LIDAR aériennes :**

Des nuages de points LIDAR, acquis en mars 2012 à Lausanne et en mai 2016 à Neuchâtel, ont été mis à disposition pour ce travail. Les nuages produits à Lausanne et à Neuchâtel sont respectivement issus d'un système Optech ALTM Gemini et Riegl LMS-Q1560.

**TABLE 3** – Spécifications des systèmes

| Système                                   | Optech ALTM Gemini              | Riegl LMS-Q1560    |
|-------------------------------------------|---------------------------------|--------------------|
| Principe du balayage                      | Miroir oscillant                |                    |
| Densité de points                         | 30-40 [ $m^{-2}$ ]              | 30-80 [ $m^{-2}$ ] |
| Nombre d'échos par impulsion              | Maximum 4                       | entre 7 et 15      |
| Précision planimétrique (1 <i>sigma</i> ) | 1/5500 $\times$ altitude de vol | —                  |
| Précision altimétrique (1 <i>sigma</i> )  | $< \sim 30$ cm                  | —                  |
| Exactitude                                | —                               | 20 mm              |
| Fréquence de balayage                     | Max. 70 [Hz]                    | Max. 400 [Hz]      |
| Divergence du faisceau                    | 0.25 [mrad]                     |                    |

Les points se présentent sous la forme d'un fichier .LAS [16]. Chaque point y est catégorisé par plusieurs attributs. Cependant ce travail ne se base que sur les attributs de localisation et de classification des points, spécifiés dans la table 2.

Les nuages de points ont été préalablement filtrés et segmentés. Ainsi chaque point désigne un écho sur la végétation haute. Il est également pourvu d'un label lui assignant une appartenance à un seul arbre. Cette segmentation a été effectuée manuellement. La position du tronc de chaque arbre est donc connue et peut être associée à une observation de terrain géoréférencée.

**Données dendrométriques :**

Des données dendrométriques (diamètre, genre et espèce) sous la forme de relevés de terrain ont été fournies par le centre de compétence en sylviculture [17] et l'Institut fédéral de recherches sur la forêt, la neige et le paysage [18].




## 2.3 Échelles d'étude et ensembles d'entraînement

La classification implique de catégoriser précisément, au préalable, le type d'observation à classer. Étant question de classer la végétation haute par le biais d'images, deux stratégies sont possibles. Le travail de classification peut être effectué à l'échelle des objets (arbres) ou à l'échelle des pixels. Dans le premier cas, les réflectances des pixels situés au sein d'une même couronne peuvent être agrégées pour créer une signature spectrale moyenne. Ainsi, dans cette étude, le travail de classification est expérimenté à deux échelles différentes.

### Observations à l'échelle de l'arbre :

Chaque arbre est représenté par un ensemble de points lidar labellisés qui peut être projeté sur l'image aéroportée. Les réflectances de chaque pixel peuvent ensuite être pondérées en fonction du nombre de points lidars qu'il contient. Il en résulte une signature spectrale agrégée formée par les réflectances moyennes des pixels contenant des échos lidars. Chaque arbre est donc à l'origine d'une unique observation dans l'ensemble de données d'entraînement.



**FIGURE 2** – Pondération des réflectances par le nombre d'échos, constituant un arbre, contenus dans chaque pixel.



### Observations à l'échelle du pixel :

L'ensemble de points labellisés de chaque arbre donne la possibilité d'estimer la forme de sa couronne telle qu'observée sur les orthophotos. Les arbres situés sous la canopée sont invisibles sur l'imagerie aérienne hyperspectrale. C'est pourquoi, chaque segment situé sous la canopée n'est pas utilisé lors de l'association des pixels aux couronnes d'arbres individuels. Les formes de ces couronnes peuvent alors être projetées sur l'image. A cette étape, un second filtrage élimine tout pixel partiellement contenu dans la projection de la couronne d'un arbre. Ceux-ci, s'ils ont des réflectances composées par plusieurs types de surfaces engendrent des observations biaisées. Finalement, les informations des observations de terrains, sont assignées aux pixels contenus entièrement dans la projection de la couronne de l'arbre qui leur correspond.

Cette méthode bien que plus compliquée a l'avantage de produire des ensembles d'entraînement avec un nombre bien plus élevé d'observations.

### Suppression des classes sous-représentées :

Les classes comportant un nombre trop restreint d'observations ont été supprimées. L'ajustement d'un modèle sur une classe sous-représentée risquerait d'engendrer un fort biais.

La table 4 détaille les dimensions des deux ensembles d'entraînement utilisés dans ce travail. Elle énonce également le nombre minimum d'observations nécessaires d'une classe.

**TABLE 4** – Détails des ensembles d'entraînement, avant pré-traitement.

| Ensemble | Échelle des observations | Représentation minimum | Dimension         |
|----------|--------------------------|------------------------|-------------------|
| 1        | assimilées aux arbres    | 19 arbres par classe   | 224 observations  |
| 2        | assimilées aux pixels    | 100 pixels par classe  | 5926 observations |

Pour préserver un nombre d'observations supérieur à 200 au sein de l'ensemble 1, il est nécessaire de conserver une classe, de variétés résiduelles non-définies (voir tableau 5). Ce choix représente une difficulté puisque ce groupe sera décrit par des aspects bien plus variables. Cependant l'approche de classification par ajustement de modèles intermédiaires, décrite en section 3.4, p.20, permettra des analyses de résultats spécifiques à chacune des classes.

### Inventaire des classes :

Les classes représentant les différentes variétés d'arbres, sont résumées au sein de la table 5. Il faut remarquer la présence d'un nombre plus élevé de classes dans l'ensemble 2. Il est probable que la difficulté d'ajustement des modèles de l'ensemble 2 en soit légèrement accrue.

**TABLE 5** – Inventaire des classes

| Genre                       | Espèce         | Division      | Nom              | Ensemble 1 | Ensemble 2 |
|-----------------------------|----------------|---------------|------------------|------------|------------|
| Acer                        | pseudoplatanus | Magnoliophyta | érable sycomore  | ✓          |            |
| Larix                       | decidua        | Coniferophyta | mélèze d'Europe  | ✓          | ✓          |
| Picea                       | abies          | Coniferophyta | épicéa commun    | ✓          | ✓          |
| Quercus                     | robur          | Magnoliophyta | chêne pédonculé  | ✓          | ✓          |
| Abies                       | alba           | Coniferophyta | sapin blanc      |            | ✓          |
| Fagus                       | sylvatica      | Magnoliophyta | hêtre commun     |            | ✓          |
| Fraxinus                    | excelsior      | Magnoliophyta | frêne élevé      |            | ✓          |
| Pinus                       | sylvestris     | Coniferophyta | pin sylvestre    |            | ✓          |
| Pseudotsuga                 | menziesii      | Coniferophyta | sapin de Douglas |            | ✓          |
| Quercus                     | petraea        | Magnoliophyta | chêne sessile    |            | ✓          |
| autres variétés résiduelles |                |               |                  | ✓          |            |

## 3 Méthodologie

Dans ce projet, il s'agit d'ajuster un modèle prédictif de classification. Le modèle doit être capable de déterminer l'espèce et le genre d'une observation, extraite à l'échelle du pixel ou de arbre, en fonction de ces descripteurs. Afin d'évaluer la configuration optimale, différents paramètres d'ajustement et différents pré-traitements des données sont mis à l'essai.

### 3.1 Compromis entre biais et variance

La problématique principale de l'ajustement de modèles prédictifs consiste en la minimisation de l'erreur de généralisation. Cette erreur de généralisation est définie par l'erreur attendue sur la prédiction d'observations absentes des données ayant servi à l'ajustement du modèle [19].

Deux composantes permettent de décrire cette erreur [20]. Une première composante appelée, biais, se traduit par un modèle trop simple ou typiquement ne comportant pas assez de paramètres. Un tel modèle, même si ajusté sur un très grand nombre d'observations, échouera toujours à décrire précisément un phénomène. Une deuxième composante se définit par la variance du processus d'ajustement. Cette variance intervient lorsqu'un modèle trop complexe est ajusté, ou typiquement lorsque la proportion de paramètres est trop importante vis-à-vis du nombre d'observations. Le modèle variera fortement en fonction des données d'ajustement car des aspects aléatoires ou indépendants du phénomène étudié seront modélisés.

En d'autres termes, l'élaboration de modèles, simples, amènent le processus d'ajustement à ne modéliser que les aspects essentiels des différents échantillons d'entraînement. Ainsi, les modèles, même entraînés sur des échantillons de taille relativement réduite, auront des résultats similaires lorsque testés avec de nouvelles données. Leurs variances seront faibles car les aspects appris seront globalement les mêmes. Cependant ces modèles risquent d'être biaisés car incapables de modéliser tous les aspects du phénomène étudié. A l'inverse, des modèles complexes, ou ayant un nombre élevé de paramètres, amènent le risque de modéliser des aspects propres à leurs échantillons d'entraînement. De fortes différences découleront des prédictions de ces modèles sur un échantillon différent, même légèrement, de l'échantillon d'entraînement. Ils auront donc une variance élevée car seront sur-ajustés.

Les tests de différentes configurations ont pour objectif d'établir le processus d'ajustement résultant en une erreur de généralisation minimum grâce à un compromis optimal entre biais et variance du modèle.

## 3.2 Définition des descripteurs

Les performances de trois types distincts de descripteurs comme variables prédictives seront évaluées sur chaque ensemble. Un premiers type est issu directement des valeurs de réflectances des orthophotos. Un deuxième type représente des indices spectraux calculés grâce aux réflectances des orthophotos. Un dernier type décrit la morphologie de l'arbre et est issu des échos LIDAR.

### **Réflectances spectrales comme variables prédictives :**

Les deux ensembles de données seront entraînés avec les réflectances de la totalité des bandes spectrales des orthophotos. Chaque réflectance correspondante à une longueur d'onde incarnera un descripteur. Les 285 bandes spectrales et leur longueur d'onde sont détaillées au sein des tables 20 et 21, situées en annexe.

### **Indices spectraux comme variables prédictives :**

Les deux ensembles de données seront entraînés avec deux groupes d'indices spectraux différents. Chaque indice spectral incarne un descripteur. La table 6 définit ces deux groupes. Ces indices et les formules servant à les calculer sont détaillés au sein des tables 18 et 19, situées en annexe.

**TABLE 6** – Descripteurs de type 2

| (a) Ensemble 1 |             | (b) Ensemble 2 |           |
|----------------|-------------|----------------|-----------|
| 1              | Bande PIR   | 1              | SR Custom |
| 2              | Bande rouge | 2              | CAI       |
| 3              | Bande verte | 3              | EVI       |
| 4              | Bande bleu  | 4              | GNDVI     |
| 5              | GNDVI       | 5              | SR        |
| 6              | CAI         | 6              | RVI       |
| 7              | CI590       | 7              | NDVI1     |
| 8              | DVI         | 8              | NDVI2     |
| 9              | EVI         | 9              | NDVI3     |
| 10             | PVI         | 10             | GVI       |
| 11             | LWI         | 11             | GI        |
| 12             | RE          | 12             | MCARI1    |
| 13             | REP         | 13             | MCARI2    |
| 14             | MSAVI       | 14             | mNDVI1    |
| 15             | MTCI        | 15             | mNDVI2    |
| 16             | NDVI        | 16             | MSAVI     |
| 17             | NDWI1240    | 17             | mSR1      |
| 18             | NDWI1640    | 18             | mSR2      |
| 19             | PRI         | 19             | MTCI      |
| 20             | PSNDa       | 20             | mTVI      |
| 21             | PSSRa       | 21             | OSAVI     |
| 22             | ARVI        | 22             | RDVI      |
| 23             | AFVI        | 23             | REIP      |
| 24             | TVI         | 24             | SIP11     |
| 25             | RVI         | 25             | SIP12     |
| 26             | SARVI       | 26             | NDWI 1240 |
| 27             | SAVI        | 27             | NDWI 1640 |
| 28             | TSAVI       | 28             | PSNDa     |
| 29             | WDRVI       | 29             | PSSRa     |
|                |             | 30             | PRI       |
|                |             | 31             | RENDVI    |
|                |             | 32             | WBI       |
|                |             | 33             | ARI       |
|                |             | 34             | BGI       |
|                |             | 35             | BRI       |
|                |             | 36             | CRI1      |
|                |             | 37             | CRI2      |
|                |             | 38             | RGI2      |
|                |             | 39             | CI        |
|                |             | 40             | LIC       |
|                |             | 41             | NPCI      |
|                |             | 42             | NPQI      |
|                |             | 43             | PRI1      |
|                |             | 44             | PRI2      |
|                |             | 45             | PSRI      |

### Indices de morphologies comme descripteurs :

L'ensemble 1 sera également entraîné avec des descripteurs de la morphologie de l'arbre correspondant à l'observation, issus des échos LIDAR. Des quantiles de distribution de la hauteurs des échos représentent l'essentiel de ces descripteurs.

- Soit  $P(Z \leq z)$ , la probabilité qu'une variable aléatoire  $Z$  soit inférieure ou égale à une valeur  $z$
- Soit  $q(p)$ , le quantile de la fraction  $p$

Le quantile de distribution de la fraction  $p$  est défini tel que :

$$P(Z \leq q(p)) = p \quad (1)$$

La table 7 détaille le groupe de descripteurs morphologiques calculés pour l'ensemble 1.

**TABLE 7** – Descripteurs de type 3 de l'ensemble 1

|    |                        |
|----|------------------------|
| 1  | $q(0.025)$ [m]         |
| 2  | $q(0.100)$ [m]         |
| 3  | $q(0.200)$ [m]         |
| 4  | $q(0.250)$ [m]         |
| 5  | $q(0.300)$ [m]         |
| 6  | $q(0.400)$ [m]         |
| 7  | $q(0.500)$ [m]         |
| 8  | $q(0.600)$ [m]         |
| 9  | $q(0.700)$ [m]         |
| 10 | $q(0.750)$ [m]         |
| 11 | $q(0.800)$ [m]         |
| 12 | $q(0.900)$ [m]         |
| 13 | $q(0.975)$ [m]         |
| 14 | Hauteur de l'arbre [m] |

### 3.3 Pré-traitements des données

#### Standardisation :

Avant l'application de méthodes de classifications, toutes les valeurs des descripteurs ont été centrées et réduites de la façon suivante :

- Soit  $N$ , le nombre d'observations de l'ensemble d'entraînement
- Soit  $x_{i,j}$ , la valeur du descripteur  $j$  de l'observation  $i$
- Soit  $\bar{x}_j$ , la moyenne du descripteur  $j$  sur l'ensemble d'entraînement tel que  $\bar{x}_j = \frac{\sum_i^N x_{i,j}}{N}$
- Soit  $s_j$ , l'écart type du descripteur  $j$  tel que  $s_j = \sqrt{\frac{1}{N} \sum_i^N (x_{i,j} - \bar{x}_j)^2}$
- Soit  $z_{i,j}$ , la valeur centrée réduite de  $x_{i,j}$

$$z_{i,j} = \frac{x_{i,j} - \bar{x}_j}{s_j} \quad (2)$$

Il en résulte des descripteurs centrés autour de zéro et dont l'intervalle de valeurs  $[-1 : 1]$  traduit l'intervalle de l'écart-type.

#### Décorrélacion et sélection de variables prédictives :

Afin d'éviter un sur-ajustement, il est intéressant d'éliminer les descripteurs superflus traduisant un niveau d'information faible ou redondant. A cette fin, l'analyse en composantes principales (ACP) est utilisée ici.

Cette méthode, permet de définir un nouveau système d'axes de projection au sein de l'espace de descripteurs. Système caractérisé par un axe, ou une première composante, orienté dans l'axe de variabilité maximale de l'ensemble de données. De plus, ces composantes sont toutes indépendantes les unes des autres. Cette analyse amène donc deux avantages. Elle offre de décorrélérer les données en adoptant toutes ses composantes principales comme de nouveaux descripteurs. Elle offre également d'établir le niveau de variabilité décrit par chacune de ces composantes. Il est alors possible de sélectionner un nombre minimum de descripteurs permettant de décrire une certaine proportion de l'information de l'ensemble de données.

Cette méthode est utilisée, ici, afin d'établir deux configurations d'ajustement différentes. Une première configuration est définie pour décorrélérer les données. L'ensemble des composantes principales y sont conservées comme nouveaux descripteurs. Une seconde dans laquelle, seul un minimum de composantes permettant de décrire 99% de la variabilité des données sera conservée. Toute autre composante sera rejetée.



Toutefois, cette méthode n'accorde aucune sélection basée sur la significativité des descripteurs vis-à-vis de la variable réponse qui doit être prédite. Elle ne s'appuie que sur les corrélations (les relations linéaires) entre les variables. D'autres méthodes, issues par exemple de l'évaluation du niveau d'information mutuel entre les descripteurs et la variable réponse existent mais ne sont pas employées dans ce travail. Cependant, une configuration, permettant une pénalisation, plus restrictive, lors du processus de sélection de modèles ayant un nombre élevé de descripteurs, est mis à l'essai dans ce travail. Cette configuration est décrite au sein du chapitre 3.4. Ce processus de pénalisation plus sévère tend à définir comme nul, les coefficients de descripteurs non-significatifs. Il est dès lors possible d'ajuster des modèles avec un nombre plus élevé de descripteurs.

Dernièrement, il faut également noter que l'analyse en composante principale peut impliquer de redimensionner l'espace de descripteurs. L'ACP ne peut reproduire plus de composantes principales qu'il n'y a de points dans l'espace de descripteurs car cela reviendrait à isoler des points dans des espaces vides. Concrètement, si cette méthode est appliquée pour décorréler les descripteurs de l'ensemble 1, celui-ci ne se verra attribuer plus que 224 descripteurs.

### **Suppression des valeurs extrêmes :**

Dans le cas de l'ensemble 2, suffisamment large, il peut être intéressant de rechercher et supprimer les observations décrites par des valeurs trop extrêmes. En effet, celle-ci peuvent, par exemple, être issues du bruit des capteurs. Elles peuvent également être engendrées par des erreurs survenues lors de l'extraction de pixels ayant des réflectances composées par plusieurs type de surfaces. La fonction de répartitions empiriques servira à définir et à filtrer les observations dont les descripteurs comportent des valeurs extrêmes.

Cependant, cette procédure, peut amener l'ensemble filtré, servant à l'ajustement, à ne plus être totalement représentatif de l'ensemble d'origine. En effet, dans le cas où une classe comporterait des aspects plus variables, ses observations pourraient être interprétées à tort comme comportant des valeurs extrêmes issues d'erreurs ou de bruit. Cette classe sera donc excessivement filtrée et sa représentation sera diminuée. Il sera donc nécessaire de s'assurer de la validité du modèle en l'évaluant sur un ensemble de validation conservé à l'écart du processus d'ajustement. Cette ensemble comportera donc 200 observations choisies de façon aléatoire.


### Recherche de variables prédictives :

Des variables prédictives peuvent parfois représenter un apport d'information, pertinente aux modèles, lorsque celles-ci sont combinées les unes avec les autres. Afin de rechercher ce type de variables sous la forme de descripteurs additionnels, et ainsi augmenter la dimensionnalité de l'espace de descripteurs sans l'utilisation de configurations d'ajustement plus complexes (voir le concept de noyau en page 21), une approche de pré-traitement, consistant à multiplier les descripteurs entre eux, sera évaluée.

## 3.4 Classification : Machine à vecteurs de support

Les modèles de prédictions basés sur des vecteurs de support appartiennent à la classe des classifieurs linéaires. Ils ont pour objectif d'établir une séparation linéaire entre les différentes classes dans l'espace de descripteurs. Les méthodes de Machine à vecteurs de support (MVS) permettent d'établir cette séparation en optimisant la marge de séparation entre les différentes classes. Il s'agit de définir cette marge par les observations situées à la limite de l'espace d'influence de leur classe. Ces observations sont alors appelées vecteurs de support.

Cette méthode a l'avantage d'opérer une optimisation convexe. Elle converge donc en toute circonstance vers un optimum local équivalent à l'optimum global. En outre, elle permet l'utilisation de noyaux dans le cas où une séparation linéaire n'est pas possible dans l'espace d'origine (voir section 3.4,p.21).



**FIGURE 3** — Visualisation de la droite de séparation linéaire de deux classes dans un espace défini par deux descripteurs. Suivant le critère de classification des vecteurs de support, la droite est ici définie par sa marge de séparation maximum. Trois observations, entourées d'un cercle, sont définies comme vecteurs de support. Image reprise de la documentation scikit-learn [21]

**Modèle de prédiction :**

$$\boxed{\text{règle de décision : } \vec{x} \cdot \vec{w} + b = l} \quad (3)$$

- Soit un vecteur  $\vec{x}$  défini par les descripteurs d'une observation.
- Soit le vecteur de paramètre  $\vec{w}$  défini par des coefficients à appliquer aux descripteurs et formant la normale à l'hyperplan de séparation de classe.
- Soit  $y$ , le score de prédiction du label de l'observation.
- Soit  $\hat{y}$ , la prédiction du label de la classe de l'observation.

La prédiction du label lors d'une classification binaire est finalisée de la façon suivante :

$$\hat{y} = \begin{cases} -1, & \text{si } y < 0 \\ +1, & \text{si } y > 0 \end{cases}$$

### Processus d'ajustement :

La méthode admet que la règle de décision appliquée aux vecteurs de support donne des valeurs unitaires [22] :

$$x_{\pm}^{\vec{}} \cdot \vec{w} + b = \pm 1$$

$$x_{\pm}^{\vec{}} \cdot \vec{w} = \pm 1 - b$$

La largeur de la marge, qui représente le critère de maximisation, peut donc se définir par un segment oblique entre deux vecteurs de support  $(x_+^{\vec{}} - x_-^{\vec{}})$ , projeté sur le vecteur unitaire perpendiculaire à l'hyperplan,  $\frac{\vec{w}}{\|\vec{w}\|}$ .

$$\text{largeur de la marge : } (x_+^{\vec{}} - x_-^{\vec{}}) \cdot \frac{\vec{w}}{\|\vec{w}\|} = \frac{2}{\|\vec{w}\|}$$

Maximiser la largeur de la marge revient donc à minimiser la norme du vecteur de paramètres,  $\|\vec{w}\|$ . Par commodité la procédure d'ajustement des méthodes de classification MVS retient généralement la minimisation de la forme suivante  $\frac{1}{2} \cdot \|\vec{w}\|^2$

En résumé, il est alors question de maximiser cette largeur de marge sous la contrainte de la règle de décision appliquée aux observations définies comme vecteurs de supports.

- Soit  $l$ , le label, connu, de la classe de l'observation, issue de l'ensemble d'entraînement.  
 $l \in \{-1; +1\}$

$$\boxed{\min \frac{1}{2} \cdot \|\vec{w}\|^2} \tag{4}$$

$$\boxed{l(x_{\pm}^{\vec{}} \cdot \vec{w} + b) - 1 = 0} \tag{5}$$

L'apprentissage du modèle revient à optimiser ce système sur la totalité de l'ensemble d'entraînement. L'approche Lagrangienne permet de solutionner le problème de la façon suivante :

- Soit  $L$ , le lagrangien définissant l'optimisation sous contrainte du système.
- Soit  $\alpha$ , le multiplicateur de Lagrange compris entre  $[0 : 1]$  et formé par un nombre de coefficients égal au nombre d'observations.

$$\boxed{L = \frac{1}{2} \cdot \|\vec{w}\|^2 - \sum \alpha_i [l_i(x_i^{\vec{}} \cdot \vec{w} + b) - 1]} \tag{6}$$

$$\frac{\partial L}{\partial w} = w - \sum \alpha_i l_i x_i, \text{ si } \frac{\partial L}{\partial w} = 0 \Rightarrow w^* = \sum \alpha_i l_i x_i \tag{7}$$

$$\frac{\partial L}{\partial b} = - \sum \alpha_i l_i, \text{ si } \frac{\partial L}{\partial b} = 0 \Rightarrow \sum \alpha_i l_i = 0 \tag{8}$$

Ainsi, en insérant l'équation 7 à l'équation 6, tout en considérant l'équation 8, le lagrangien se décrit sous la forme suivante :

$$L = \sum_i^N \alpha_i - \frac{1}{2} \sum_i^N \sum_j^N \alpha_i \alpha_j l_i l_j x_i x_j \quad (9)$$

Le processus d'ajustement revient alors à définir les paramètres  $\alpha^*$  et  $w^*$  tels que :

$$\underset{\alpha \in [0:1]}{\operatorname{argmax}} \underset{w}{\operatorname{argmin}} L = \frac{1}{2CF_i} \cdot \|\vec{w}^*\|^2 - \sum \alpha_{*i} [l_i(\vec{x}_i \cdot \vec{w}^* + b) - 1] \quad (10)$$

Le vecteur de coefficients  $\alpha_*$  permet de décrire la position des observations situées à l'intérieur ou à la limite de la marge. Les observations ne formant pas un vecteur de support, en dehors de la marge, sont donc pourvue d'un coefficient  $\alpha_{*i}$  nul.

Notons l'insertion d'un nouveau paramètre,  $C$ , permettant d'ajuster la pénalisation de complexité du modèle. En effet, la minimisation de la norme de  $w$ , revient à pénaliser les solutions complexes ne comportant que des coefficients de magnitude élevée. Un paramètre  $C$  proche de 0 confèrera plus de poids à la minimisation de cette norme lors de l'optimisation du Lagrangien. La solution  $w$  comportera alors des coefficients faibles. Il en résultera un modèle simplifié car certains descripteurs seront très peu pris en compte. Ce paramètre servira également à contrer le déséquilibre de représentation des classes. Il sera donc ajusté selon la fréquence de la classe  $F_i$  de l'observation au sein de l'ensemble d'entraînement.

Dans le cas présent, il s'agit d'entraîner des modèles ayant plus de deux classes. Chaque modèle décrit dans ce travail sera en réalité le résultat de l'ajustement d'un modèle, intermédiaire pour chaque classe. Ces modèles intermédiaires seront de type "un contre le reste". La classe prédite pour une observation reviendra au score  $y$  le plus élevé parmi les modèles intermédiaires.

Toutes les procédures d'ajustements et de classifications utilisées dans cette étude ont été réalisées avec la toolbox **Scikit-learn**[21] de python.

### Noyau :

Comme le montre la section précédente, les classifieurs MVS visent à établir une séparation linéaire entre les classes en maximisant la largeur de la marge dans l'espace des descripteurs. Toutefois, il peut arriver que cet espace ne permette pas une telle délimitation linéaire. Dans ces cas, il est utile d'augmenter le nombre de dimension de l'espace. A cette fin, les méthodes de classifications MVS ont l'avantage de donner la possibilité d'utiliser des noyaux.

L'équation 9 montre que l'ajustement d'un classifieur MVS, implique les vecteurs d'observation,  $x_i$ , uniquement sous la forme du produit scalaire :

$$\sum_i^N \sum_j^N \alpha_i \alpha_j l_i l_j \mathbf{x}_i \mathbf{x}_j \quad (11)$$

- Soit  $x_i \in \mathbb{R}^d$ , l'observation  $x_i$  dans l'espace de descripteurs
- Soit  $z_i \in \mathbb{R}^q$  avec  $q > d$ , la projection de l'observation  $x_i$  dans l'espace complexe.

En temps normal, la définition d'un nouvel espace ayant un nombre plus élevé de dimensions implique de définir la fonction de transformation suivante :

$$\phi(x_i) = z_i \quad (12)$$

L'ajustement du classifieur dans l'espace complexe s'effectue en permutant  $x$  par  $z$  :

$$\sum_i^N \sum_j^N \alpha_i \alpha_j l_i l_j \mathbf{z}_i \mathbf{z}_j \quad (13)$$

Cependant, il est possible de simplifier la procédure lorsque la forme du noyau est connu.

- Soit  $K$ , la fonction du noyau tel que  $K(x_i, x_j) = z_i z_j$

L'ajustement est alors simplifié de la façon suivante :

$$L = \sum_i^N \alpha_i - \frac{1}{2} \sum_i^N \sum_j^N \alpha_i \alpha_j l_i l_j \mathbf{K}(\mathbf{x}_i, \mathbf{x}_j) \quad (14)$$

Dans ce travail, le noyau de fonction à base radiale sera employé :

$$K(x_i, x_j) = \exp(\gamma |x_i - x_j|^2) \quad (15)$$

Ce noyau a la particularité de convertir les observations sous la forme de combinaisons linéaires de base radiale de centre  $x_i$ , avec  $i \in N$ . Il permet ainsi de transgresser la contrainte de linéarité de l'espace initial. En effet, il peut être démontré que l'espace de  $\phi(x_i)$  est de dimension potentiellement infini [11, 23, 24].

Dans cette étude, les configurations avec noyaux de type RBF et sans noyaux (ou avec noyaux linéaires) seront testées. Trois types de pré-traitement seront également évalués. Un premier, consistant à rechercher de nouvelles variables prédictives sous la forme de facteurs de variables existantes, multipliées entre elles. Dans cette configuration, la norme dite "L1" sera appliquée au vecteur  $w$  dans l'équation 10 (concrètement  $\|w\|^2$  deviendra  $|w|$ ). Cela mène à des coefficients de  $w$  nuls. La solution est alors simplifiée car partiellement nulle. Un deuxième consiste à décorréler les descripteurs en les remplaçant par la totalité des composantes principales d'une ACP. Un dernier, dans lequel il s'agira d'utiliser l'ACP pour cette fois sélectionner le minimum de variables prédictives traduisant 99% de la variance des données.

Dernièrement, les ajustements de l'ensemble 2 combinés avec une recherche de variables prédictives, seront effectués avec la technique de descente de gradient stochastique. Cette méthode est une variante d'une MVS classique dans laquelle le gradient est calculé sur un sous-ensemble d'observations choisi aléatoirement lors de chaque itérations. Lors d'une MVS classique, plus gourmande en temps de calcul, ce gradient est calculé sur la base de la totalité des données.

### 3.5 Sélection du modèle

#### Validation croisée :

Afin d'évaluer la qualité des modèles, ceux-ci sont testés suivant la méthode de validation croisée : Lors de chaque processus d'ajustement d'un modèle, l'ensemble d'entraînement est divisé en plusieurs sous-ensembles. C'est sous-ensembles sont stratifiés car ils conservent les proportions d'origines des classes. Le modèle est alors ajusté à autant de reprises qu'il y a de sous-ensembles. A chaque fois, un des sous-ensembles est retiré de l'ensemble d'entraînement et conservé pour l'évaluation du modèle. La performance globale du modèle est évaluée sur la base du score moyen de prédiction des sous-ensembles.

Opter pour un nombre élevé de sous-ensembles permet de stabiliser l'évaluation de la performance globale du modèle. A l'inverse un nombre trop élevé pourrait induire des sous-ensembles de taille trop réduite, non-représentatifs de l'ensemble d'entraînement. La validation croisée sera effectuée avec 4 sous-ensembles de l'ensemble 1 et 10 sous-ensembles de l'ensemble 2.

### Évaluation de la qualité du modèle :

Chaque phase d'ajustement d'un modèle est donc finalisée par la prédiction du sous-ensemble préalablement retiré de l'ensemble d'entraînement. Trois indices permettent de comparer les prédictions avec les valeurs vraies des labels.

- Soit  $vp$ , le nombre de vrais positifs au sein des prédictions d'une classe
- Soit  $fp$ , le nombre de faux positifs au sein des prédictions d'une classe
- Soit  $fn$ , le nombre de faux négatifs au sein des prédictions d'une classe

Une matrice de confusion simple, illustrée par le table 8, détaille l'évaluation des résultats d'un modèle.

**TABLE 8** – Matrice de confusion constituée par les résultats des prédictions ( $vp$ ,  $fp$ ,  $fn$ ,  $vn$ )

|         |      | Prédictions |      |
|---------|------|-------------|------|
|         |      | Vrai        | Faux |
| Réalité | Vrai | $vp$        | $fn$ |
|         | Faux | $fp$        | $vn$ |

$$\text{Précision : } P = \frac{vp}{(vp + fp)} \quad (16)$$

$$\text{Rappel : } R = \frac{vp}{(vp + fn)} \quad (17)$$

$$\text{F-mesure : } F1 = 2 \cdot \frac{P \cdot R}{P + R} \quad (18)$$

La F-mesure est une valeur comprise entre  $[0 : 1]$  permettant d'évaluer la qualité du modèle dans la prédiction d'une des classes. Une valeur maximum est souhaitable. Afin d'évaluer le modèle dans son ensemble, la F-mesure est considérée dans ce travail comme la moyenne de chacune des classes.





## 4 Résultats

### 4.1 Ensemble d'entraînement 1

**TABLE 9** – Résultats des observations à l'échelle de l'arbre : F-mesures moyennes des sous-ensembles de validation

(a) Résultats des classifications de réflectances

| Noyau    | ACP décorrélation | ACP 99% | Multiplicateur de D. | D. Lidar | F-mesure |
|----------|-------------------|---------|----------------------|----------|----------|
| Linéaire |                   |         |                      |          | 0.664    |
| Linéaire | ✓                 |         |                      |          | 0.667    |
| Linéaire |                   | ✓       |                      |          | 0.567    |
| Linéaire |                   |         | ✓                    |          | 0.598    |
| Linéaire | ✓                 |         | ✓                    |          | 0.647    |
| Linéaire |                   | ✓       | ✓                    |          | 0.550    |
| Linéaire |                   |         |                      | ✓        | 0.714    |
| Linéaire | ✓                 |         |                      | ✓        | 0.716    |
| Linéaire |                   | ✓       |                      | ✓        | 0.602    |
| Linéaire |                   |         | ✓                    | ✓        | 0.672    |
| Linéaire | ✓                 |         | ✓                    | ✓        | 0.691    |
| Linéaire |                   | ✓       | ✓                    | ✓        | 0.599    |
| FBR      |                   |         |                      |          | 0.669    |
| FBR      | ✓                 |         |                      |          | 0.657    |
| FBR      |                   | ✓       |                      |          | 0.642    |
| FBR      |                   |         | ✓                    |          | 0.620    |
| FBR      | ✓                 |         | ✓                    |          | 0.665    |
| FBR      |                   | ✓       | ✓                    |          | 0.624    |
| FBR      |                   |         |                      | ✓        | 0.725    |
| FBR      | ✓                 |         |                      | ✓        | 0.760    |
| FBR      |                   | ✓       |                      | ✓        | 0.653    |
| FBR      | ✓                 |         | ✓                    | ✓        | 0.726    |
| FBR      |                   | ✓       | ✓                    | ✓        | 0.667    |

(b) Résultats des classifications d'indices

| Noyau    | ACP décorrélation | ACP 99% | Multiplicateur de D. | D. Lidar | F-mesure |
|----------|-------------------|---------|----------------------|----------|----------|
| Linéaire |                   |         |                      |          | 0.638    |
| Linéaire | ✓                 |         |                      |          | 0.657    |
| Linéaire |                   | ✓       |                      |          | 0.611    |
| Linéaire |                   |         | ✓                    |          | 0.658    |
| Linéaire | ✓                 |         | ✓                    |          | 0.658    |
| Linéaire |                   | ✓       | ✓                    |          | 0.635    |
| Linéaire |                   |         |                      | ✓        | 0.707    |
| Linéaire | ✓                 |         |                      | ✓        | 0.707    |
| Linéaire |                   | ✓       |                      | ✓        | 0.697    |
| Linéaire |                   |         | ✓                    | ✓        | 0.709    |
| Linéaire | ✓                 |         | ✓                    | ✓        | 0.711    |
| Linéaire |                   | ✓       | ✓                    | ✓        | 0.695    |
| FBR      |                   |         |                      |          | 0.621    |
| FBR      | ✓                 |         |                      |          | 0.635    |
| FBR      |                   | ✓       |                      |          | 0.614    |
| FBR      |                   |         | ✓                    |          | 0.652    |
| FBR      | ✓                 |         | ✓                    |          | 0.651    |
| FBR      |                   | ✓       | ✓                    |          | 0.624    |
| FBR      |                   |         |                      | ✓        | 0.756    |
| FBR      | ✓                 |         |                      | ✓        | 0.720    |
| FBR      |                   | ✓       |                      | ✓        | 0.697    |
| FBR      |                   |         | ✓                    | ✓        | 0.727    |
| FBR      | ✓                 |         | ✓                    | ✓        | 0.730    |
| FBR      |                   | ✓       | ✓                    | ✓        | 0.715    |

**TABLE 10** – Résultats des classifications de descripteurs Lidar uniquement

| Noyau    | ACP décorrélation | ACP 99% | Multiplicateur de D. | F-mesure |
|----------|-------------------|---------|----------------------|----------|
| Linéaire |                   |         |                      | 0.518    |
| Linéaire | ✓                 |         |                      | 0.445    |
| Linéaire |                   | ✓       |                      | 0.412    |
| Linéaire |                   |         | ✓                    | 0.523    |
| Linéaire | ✓                 |         | ✓                    | 0.491    |
| Linéaire |                   | ✓       | ✓                    | 0.377    |
| FBR      |                   |         |                      | 0.576    |
| FBR      | ✓                 |         |                      | 0.571    |
| FBR      |                   | ✓       |                      | 0.603    |
| FBR      |                   |         | ✓                    | 0.567    |
| FBR      | ✓                 |         | ✓                    | 0.567    |
| FBR      |                   | ✓       | ✓                    | 0.583    |

Les tableaux 9 et 10 détaillent les performances des configurations d’ajustements testés sur les ensembles de données d’entraînement dont les observations sont à l’échelle des arbres. Du fait de temps de calcul trop conséquent l’ajustement d’un modèle avec noyau FBR sur les descripteurs mixtes, réflectances et LIDAR, sans aucune décorrélation ou sélection des descripteurs, n’a pas été mené.

L’analyse en composante principale pour décorréler les descripteurs, amène généralement une amélioration, parfois très légère des résultats. Deux cas présentent une situation opposée. Le modèle avec noyau FBR appliqué aux réflectances qui voit sa F-mesure diminuée de 0.012. Dans ce cas-ci, la réduction obligatoire de la dimensionnalité de l’espace de descripteurs (perte de 61 dimensions) alliée à une pénalisation déjà satisfaisante pourrait expliquer cette perte de performance. Un deuxième cas, où la décorrélation par l’ACP se montre contre-productive, est le modèle avec noyau FBR appliqué à l’ensemble d’indices spectraux et de descripteurs LIDAR. Ce modèle diminue fortement avec une perte de performance de 0.026. Il est difficile d’expliquer cette variation d’autant, que l’ACP n’occasionne aucune baisse de dimensionnalité des descripteurs, puisque ceux-ci sont

en nombre inférieur au nombre d'observation.

L'analyse en composante principale pour sélectionner les descripteurs traduisant le mieux 99% de l'ensemble amène très souvent des revers. La baisse de performance est presque systématique et souvent considérable. Une exceptions subsiste avec le modèle usant du noyau RBF appliqué aux descripteurs de réflectances démultipliés entre eux avant l'ACP. La sélection des descripteurs décorrélés responsables de 99% de variance signifie souvent de ne garder qu'une dizaine de descripteurs. Cette réduction de dimensionnalité peut être trop sévère.

L'augmentation de la dimensionnalité de l'espace de descripteurs par l'ajout de leurs combinaisons comme facteurs les uns des autres n'est pas efficace dans le cas des modèles appliqués aux réflectances. Seuls deux modèles avec noyau FBR montrent une amélioration de performance avec ce pré-traitement. Le modèle entraîné sur les réflectances décorrélés, dont la F-mesure augmente légèrement de 0.08 et celui entraîné sur les descripteurs mixtes, réflectances et LIDAR, sélectionnés par l'ACP après la démultiplication. Dans le cas des indices spectraux la conclusion est inverse. Ce pré-traitement améliore presque systématiquement, même très légèrement, les prédictions. Seul l'ajustement sur les descripteurs mixtes, sans aucun autres pré-traitement, traduit une contre-performance significative. Sa mesure de performance baisse de 0.019 avec l'augmentation de dimensionnalité. Ce pré-traitement n'est ici utile qu'en cas de dimension fortement réduite ou inférieure de l'espace de descripteurs par rapport au nombre d'observations.


Le bénéfice de l'ajout de descripteurs, issus des échos LIDAR, est sans équivoque. Il permet une augmentation systématique et considérable des performances de chaque modèle. Ces nouveaux descripteurs sont donc significatifs. Toutefois, seuls, ils génèrent des performances nettement inférieures a celles des descripteurs hyperspectraux. L'utilisation de ces deux types de descripteurs est donc parfaitement complémentaire.

Globalement, les mêmes niveaux de performance peuvent être atteints avec les descripteurs de réflectances comme avec les indices calculés. Les méthodes efficaces de pré-traitements des données sont toutefois différentes en fonction des deux approches. La décorrélation des descripteurs de réflectances est un choix avantageux mais l'augmentation de leur dimensionnalité est superficielle et contre-productive. À l'inverse, l'augmentation de la dimensionnalité des descripteurs d'indices avant l'utilisation d'une ACP est le plus souvent la stratégie optimale.

### Meilleur modèle : noyau FBR, ACP décorrélation, avec descripteurs LIDAR

Les meilleurs performances sont acquises via l'ajustement d'un modèle de classification avec noyau FBR après décorrélation des descripteurs de réflectances hyperspectrales et LIDAR. La figure 4 montre les étapes de l'ajustement lors desquelles les paramètres, C et gamma, optimaux sont recherchés.

**FIGURE 4** – Ajustement du modèle en fonction du paramètre, gamma, du noyau et C, de la pénalisation. (Meilleure performance : C = 366.52, gamma = 4.9238e-5, F1-mesure = 0.760, Exactitude = 0.768)



Les tables 11 et 12 permettent d'observer en détails les résultats du meilleur et du pire sous-ensemble de validation. Elles montrent, les scores de précision, de rappel, de F-mesure et l'occurrence correspondant à chaque classe du sous-ensemble. La matrice de confusion, qui offre une vue d'ensemble des résultats, est également visible.

La classe *Quercus robur* est facilement détectée. Elle peut cependant produire quelques faux positifs, même si elle conserve l'un des plus hauts score de précision du meilleur sous-ensemble de validation. La classe *Picea abies* semble avoir des performances stables puisque ses scores sont relativement constants et toujours élevés. Avec l'une des meilleures F-mesure, elle produit à la fois peu de faux négatifs et peu de faux positifs.

Les classes ayant de faibles représentations ont les meilleures performances, ce qui conforte la qualité de la pondération du paramètre de pénalisation par la fréquence de la classe. La dernière classe, de variétés résiduelles, est clairement responsable d'une baisse de qualité des résultats généraux. Avec un score de rappel constamment bas, elle semble particulièrement difficile à détecter. Cela reste cohérent puisque sa variabilité est plus grande, cependant les scores moyens de F-mesure des deux sous-ensembles seraient considérablement plus élevés sans cette classe. Ceux-ci s'élèveraient à 0.8942 pour le premier sous-ensemble et 0.8151 pour le second. La performance moyenne de prédiction des quatre classes d'arbres, définis spécifiquement, est donc située dans cet intervalle. Compte tenu de la taille réduite de l'échantillon d'entraînement (224 arbres), cela traduit une qualité élevée du modèle.

**TABLE 11** – Résultats du meilleur sous-ensemble de validation (Noyau : FBR, ACP décorrélation, avec descripteurs Lidar)

| Groupe              | Précision | Rappel | F-mesure | Occurrence | Matrice de confusion<br>Prédictions |       |       |       |       |
|---------------------|-----------|--------|----------|------------|-------------------------------------|-------|-------|-------|-------|
|                     |           |        |          |            | A. v.                               | A. p. | L. d. | P. a. | Q. r. |
| Autres variétés     | 1         | 0.54   | 0.70     | 13         | 7                                   | 0     | 0     | 0     | 6     |
| Acer pseudoplatanus | 0.74      | 0.94   | 0.83     | 18         | 0                                   | 17    | 0     | 0     | 1     |
| Larix decidua       | 0.83      | 1      | 0.91     | 5          | 0                                   | 0     | 5     | 0     | 0     |
| Picea abies         | 1         | 0.88   | 0.93     | 8          | 0                                   | 0     | 1     | 7     | 0     |
| Quercus robur       | 0.92      | 1      | 0.96     | 12         | 0                                   | 0     | 0     | 0     | 12    |
| Moy./Tot.           | 0.88      | 0.86   | 0.85     | 56         |                                     |       |       |       |       |

**TABLE 12** – Résultats du pire sous-ensemble de validation (Noyau : FBR, ACP décorrélation, avec descripteurs Lidar)

| Groupe              | Précision | Rappel | F-mesure | Occurrence | Matrice de confusion<br>Prédictions |       |       |       |       |
|---------------------|-----------|--------|----------|------------|-------------------------------------|-------|-------|-------|-------|
|                     |           |        |          |            | A. v.                               | A. p. | L. d. | P. a. | Q. r. |
| Autres variétés     | 0.57      | 0.31   | 0.40     | 13         | 4                                   | 4     | 0     | 0     | 5     |
| Acer pseudoplatanus | 0.78      | 0.74   | 0.76     | 19         | 3                                   | 14    | 0     | 0     | 2     |
| Larix decidua       | 1         | 0.80   | 0.89     | 5          | 0                                   | 0     | 4     | 1     | 0     |
| Picea abies         | 0.90      | 1      | 0.95     | 9          | 0                                   | 0     | 0     | 9     | 0     |
| Quercus robur       | 0.63      | 1      | 0.77     | 12         | 0                                   | 0     | 0     | 0     | 12    |
| Moy./Tot.           | 0.74      | 0.74   | 0.72     | 58         |                                     |       |       |       |       |

## 4.2 Ensemble d'entraînement 2

La table 13 illustre les résultats obtenus à partir de l'ensemble d'entraînement avec des observations assimilés aux pixels. Afin de garder des temps d'ajustement comparables avec ceux de l'ensemble 1, les modèles de l'ensemble 2 n'ont été ajustés qu'avec des noyaux linéaires.

**TABLE 13** – Résultats des observations à l'échelle du pixel : F-mesures moyennes des sous-ensembles de validation

(a) Résultats des classification de réflectances

| Noyau    | ACP décorrélation | ACP 99% | Multiplicateur de D. | F-mesure |
|----------|-------------------|---------|----------------------|----------|
| Linéaire |                   |         |                      | 0.721    |
| Linéaire | ✓                 |         |                      | 0.724    |
| Linéaire |                   | ✓       |                      | 0.629    |
| Linéaire |                   |         | ✓                    | 0.680    |
| Linéaire | ✓                 |         | ✓                    | 0.691    |
| Linéaire |                   | ✓       | ✓                    | 0.553    |

(b) Résultats des classification d'indices

| Noyau    | ACP décorrélation | ACP 99% | Multiplicateur de D. | F-mesure |
|----------|-------------------|---------|----------------------|----------|
| Linéaire |                   |         |                      | 0.667    |
| Linéaire | ✓                 |         |                      | 0.663    |
| Linéaire |                   | ✓       |                      | 0.616    |
| Linéaire |                   |         | ✓                    | 0.664    |
| Linéaire | ✓                 |         | ✓                    | 0.666    |
| Linéaire |                   | ✓       | ✓                    | 0.620    |

Les mêmes conclusions qu'en section 4.1 sont possibles au sujet des pré-traitements des données. La décorrélation par l'analyse en composante principale amène souvent un gain faible des performances mais rarement une perte.

La sélection de variable par l'ACP semble par contre inefficace. Elle induit systématiquement une dégradation des performances. La reconstitution de seulement 99% de la variance de l'ensemble est insuffisante et semble ne pas permettre la modélisation des aspects distinctifs des classes.


L'ajout de facteurs de descripteurs est inefficace lors de l'utilisation de réflectances comme descripteurs. Les performances en sont systématiquement détériorées. Lors de l'utilisation des indices comme descripteurs, la situation est plus contrastée. L'ajout est parfois bénéfique.



Globalement les résultats issus des modèles de prédictions établis sur la base d'indices, sont décevants. Dans l'ensemble 1, ce type de descripteurs parvenait à des qualités de prédictions du même ordre que celles atteintes avec les réflectances. Au contraire, l'ensemble 2 montre une réelle marge de qualités en fonction de ces deux types. Les modèles intermédiaires de type "un contre le reste" ajustés avec des noyaux linéaires sur des indices spectraux comme seuls descripteurs, semblent biaisés quelque soit la taille de l'ensemble d'ajustement.

Les résultats issus des modèles de prédictions établis sur la base de réflectances sont toutefois prometteurs. Sans la complémentarité apportée par les descripteurs morphologiques, les scores des modèles les plus simples dépassent les 0.72. L'ajout de facteurs de descripteurs est contre-productif. Les 285 descripteurs de réflectances sont suffisants pour trouver une solution satisfaisante et sont ajustés efficacement grâce au nombre élevé d'observations.

La figure 5 montre les étapes de l'ajustement et la recherche du paramètre C, optimal.



**FIGURE 5** – Ajustement du modèle en fonction du paramètre, gamma. (Meilleure performance :  $C = \exp(-1.5172)$ , F1-mesure = 0.724, Exactitude = 0.746)

Les tables 14 et 15 laissent observer le détail des résultats du meilleur et du pire sous-ensemble de validation. Il faut remarquer la disparition de 3 classes, dont les représentations sont passées sous le seuil minimal lors de la suppression des observations comportant des valeurs extrêmes.

**TABLE 14** – Résultats du meilleur sous-ensemble de validation (Noyau : Linéaire, décorrélation)

| Groupe                | Précision | Rappel | F-mesure | Occurrence | Matrice de confusion<br>Prédictions |      |      |      |      |     |
|-----------------------|-----------|--------|----------|------------|-------------------------------------|------|------|------|------|-----|
|                       |           |        |          |            | A.a.                                | F.s. | L.d. | P.m. | Q.p. | Q.r |
| Albies alba           | 0.5       | 0.14   | 0.22     | 14         | 2                                   | 0    | 1    | 3    | 8    | 0   |
| Fagus sylvatica       | 0.80      | 1      | 0.89     | 40         | 0                                   | 40   | 0    | 0    | 0    | 0   |
| Larix decidua         | 0.96      | 0.96   | 0.96     | 24         | 0                                   | 1    | 23   | 0    | 0    | 0   |
| Pseudotsuga menziesii | 0.82      | 0.92   | 0.87     | 25         | 1                                   | 1    | 0    | 23   | 0    | 0   |
| Quercus petraea       | 0.90      | 0.86   | 0.88     | 85         | 1                                   | 8    | 0    | 2    | 73   | 1   |
| Quercus robur         | 0.96      | 1      | 0.98     | 24         | 0                                   | 0    | 0    | 0    | 0    | 24  |
| Moy./Tot.             | 0.86      | 0.87   | 0.86     | 212        |                                     |      |      |      |      |     |

**TABLE 15** – Résultats du pire sous-ensemble de validation (Noyau : Linéaire, décorrélation)

| Groupe                | Précision | Rappel | F-mesure | Occurrence | Matrice de confusion<br>Prédictions |      |      |      |      |     |
|-----------------------|-----------|--------|----------|------------|-------------------------------------|------|------|------|------|-----|
|                       |           |        |          |            | A.a.                                | F.s. | L.d. | P.m. | Q.p. | Q.r |
| Albies alba           | 0.29      | 0.13   | 0.18     | 15         | 2                                   | 5    | 3    | 3    | 0    | 2   |
| Fagus sylvatica       | 0.59      | 0.80   | 0.68     | 40         | 0                                   | 32   | 0    | 0    | 0    | 8   |
| Larix decidua         | 0.63      | 0.92   | 0.75     | 24         | 0                                   | 0    | 22   | 0    | 0    | 2   |
| Pseudotsuga menziesii | 0.56      | 0.96   | 0.71     | 25         | 0                                   | 1    | 0    | 24   | 0    | 0   |
| Quercus petraea       | 1         | 0.40   | 0.57     | 85         | 5                                   | 15   | 10   | 16   | 34   | 5   |
| Quercus robur         | 0.57      | 0.96   | 0.72     | 24         | 0                                   | 1    | 0    | 0    | 0    | 23  |
| Moy./Tot.             | 0.73      | 0.64   | 0.62     | 213        |                                     |      |      |      |      |     |

La classe *Albies alba* est la cause d’une détérioration de la performance générale des modèles. Ses scores de rappel et de précision sont systématiquement sous la barre des 0.35. Cette classe est aussi la moins représentée ce qui peut rendre plus ardu l’ajustement d’un modèle intermédiaire efficace. Cela expliquerait la difficulté des modèles à la détecter et à la distinguer des autres.

La prédiction de la classe *Fagus sylvatica* est légèrement moins stable que les autres car l’erreur de généralisation de sa prédiction varie fortement en fonction des deux sous-ensembles de validation. Comparativement à l’ensemble 1, les qualités de prédictions de l’ensemble 2 semblent moins stables.

Les table 16 et 17 détaillent la seconde validation de l’ajustement, effectuée cette fois sur l’échantillon de validation non-filtré.

**TABLE 16** – Résultats du meilleur sous-ensemble de validation sur un échantillon non-filtré  
(Noyau : Linéaire, décorrélation)

| Groupe                       | Précision | Rappel | F-mesure | Occurrence | Matrice de confusion<br>Prédictions |      |      |     |      |      |
|------------------------------|-----------|--------|----------|------------|-------------------------------------|------|------|-----|------|------|
|                              |           |        |          |            | A.a.                                | F.s. | L.d. | P.m | Q.p. | Q.r. |
| <i>Albies alba</i>           | 0.57      | 0.21   | 0.31     | 19         | 4                                   | 5    | 2    | 0   | 8    | 0    |
| <i>Fagus sylvatica</i>       | 0.85      | 0.81   | 0.83     | 72         | 0                                   | 58   | 8    | 3   | 3    | 0    |
| <i>Larix decidua</i>         | 0.52      | 0.81   | 0.63     | 16         | 1                                   | 0    | 13   | 2   | 0    | 0    |
| <i>Pseudotsuga menziesii</i> | 0.74      | 0.91   | 0.82     | 22         | 1                                   | 0    | 1    | 20  | 0    | 0    |
| <i>Quercus petraea</i>       | 0.80      | 0.81   | 0.80     | 53         | 1                                   | 5    | 1    | 2   | 43   | 1    |
| <i>Quercus robur</i>         | 0.95      | 1      | 0.97     | 18         | 0                                   | 0    | 0    | 0   | 0    | 18   |
| Moy./Tot.                    | 0.78      | 0.78   | 0.77     | 200        |                                     |      |      |     |      |      |

**TABLE 17** – Résultats du pire sous-ensemble de validation sur un échantillon non-filtré (Noyau : Linéaire, décorrélation)

| Groupe                | Précision | Rappel | F-mesure | Occurrence | Matrice de confusion<br>Prédictions |      |      |     |      |      |
|-----------------------|-----------|--------|----------|------------|-------------------------------------|------|------|-----|------|------|
|                       |           |        |          |            | A.a.                                | F.s. | L.d. | P.m | Q.p. | Q.r. |
| Albies alba           | 0.33      | 0.26   | 0.29     | 19         | 5                                   | 3    | 3    | 0   | 8    | 0    |
| Fagus sylvatica       | 0.85      | 0.65   | 0.74     | 72         | 8                                   | 47   | 10   | 2   | 5    | 0    |
| Larix decidua         | 0.43      | 0.81   | 0.57     | 16         | 0                                   | 0    | 13   | 2   | 1    | 0    |
| Pseudotsuga menziesii | 0.77      | 0.91   | 0.83     | 22         | 1                                   | 0    | 1    | 20  | 0    | 0    |
| Quercus petraea       | 0.75      | 0.79   | 0.77     | 53         | 1                                   | 4    | 3    | 2   | 42   | 1    |
| Quercus robur         | 0.94      | 0.94   | 0.94     | 18         | 0                                   | 0    | 0    | 0   | 0    | 17   |
| Moy./Tot.             | 0.74      | 0.72   | 0.72     | 200        |                                     |      |      |     |      |      |

Malgré une distribution légèrement différente de la représentation des classes, les ajustements ont une qualité de prédictions bien plus stable, sur ce nouvel échantillon. La présence possible de valeurs extrêmes au sein des descripteurs ne semble pas porter atteinte aux performances des deux modèles.

La classe *Albies alba* représente toujours le talon d'Achille de ces modèles. *Larix decidua* porte de faibles scores de précision ce qui témoigne d'une faible capacité de distinction de cette classe. *Fagus sylvatica*, quant à elle, est parfois difficile à détecter et peut être confondu avec *Larix decidua*. Étonnamment, ces deux variétés appartiennent à des familles différentes puisque *Larix d.* s'intègre dans la division des conifères et *Fagus s.* dans celle des feuillus. Cette difficulté de distinction entre *Fagus s.* et *Larix d.* est déjà visible lors de la première validation (table 14 et 15).

## 5 Conclusion

Finalement, ce travail démontre le potentiel de deux approches de classification de la végétation basées sur deux échelles différentes des observations. L'approche basée sur la classification d'observations représentant l'arbre, permet l'ajustement de modèle de qualité avec des échantillons de taille réduite. Ses modèles doivent, toutefois, disposer de suffisamment de descripteurs, spectraux et morphologiques.

La complémentarité de descripteurs issus de capteurs spectraux et d'échos LIDAR est avérée. Avec l'ajout d'un nombre restreint de descripteurs, se limitant à décrire la répartition des échos d'un arbre sur l'axe verticale, le gain de performance est considérable et systématique.

L'utilisation d'un nombre élevé de descripteurs engendrés directement par les réflectances permet l'ajustement de modèles de configurations (noyaux) plus simples à condition de disposer d'un nombre élevé d'observations. A l'inverse, un nombre plus faible de descripteurs, calculés sur la base d'indices spectraux combinés avec des configurations d'ajustements de complexités équivalentes tend à générer des modèles biaisés.

Une amélioration pourrait être proposée en ajustant des modèles de type "un contre un". Si un modèle ne parvient pas à définir une séparation linéaire entre une classe et les autres, il pourra plus certainement déterminer une séparation linéaire entre chaque classe et les combiner. Les performances des classifications basées sur des indices spectraux pourraient en être améliorées. Le temps de calcul risquerait toutefois d'en être considérablement rallongé. Pour 6 classes, chaque modèle ne nécessiterait plus d'ajuster 6 modèles intermédiaires mais 720.

Finalement, l'ajout à l'ensemble 1 de descripteurs représentant la morphologie de l'arbre visible sur chaque pixel laisse espérer de très bonnes performances de classification.

## Références

- [1] Christopher Small and Jacqueline W. T. Lu. Estimation and vicarious validation of urban vegetation abundance by spectral mixture analysis. *Remote Sensing of Environment*, 100(4) :441–456, February 2006.
- [2] Nesrine Chehata, Li Guo, and Clément Mallet. Airborne lidar feature selection for urban classification using random forests. In *Proceedings of the ISPRS Workshop : Laserscanning'09*, pages 207–212, 2009.
- [3] H. Guan, J. Yu, J. Li, and L. Luo. Random Forests-Based Feature Selection for Land-Use Classification Using LIDAR Data and Orthoimagery. *ISPRS - International Archives of the Photogrammetry, Remote Sensing and Spatial Information Sciences*, 39B7 :203–208, July 2012.
- [4] Qian Yu, Peng Gong, Nick Clinton, Greg Biging, Maggi Kelly, and Dave Schirokauer. Object-based detailed vegetation classification with airborne high spatial resolution remote sensing imagery. *Photogrammetric Engineering and Remote Sensing*, 2006.
- [5] Thoreau Rory Tooke, Nicholas C. Coops, Nicholas R. Goodwin, and James A. Voogt. Extracting urban vegetation characteristics using spectral mixture analysis and decision tree classifications. *Remote Sensing of Environment*, 113(2) :398–407, February 2009.
- [6] Isabelle Guyon and André Elisseeff. An Introduction to Variable and Feature Selection. *J. Mach. Learn. Res.*, 3 :1157–1182, March 2003.
- [7] S. De Backer, P. Kempeneers, W. Debruyn, and P. Scheunders. A band selection technique for spectral classification. *IEEE Geoscience and Remote Sensing Letters*, 2(3) :319–323, July 2005.
- [8] D. J. Wiersma and D. A. Landgrebe. Analytical Design of Multispectral Sensors. *IEEE Transactions on Geoscience and Remote Sensing*, GE-18(2) :180–189, April 1980.
- [9] Kurt Prospere, Kurt McLaren, and Byron Wilson. Plant Species Discrimination in a Tropical Wetland Using In Situ Hyperspectral Data. *Remote Sensing*, 6(9) :8494–8523, September 2014.
- [10] Edward W. Bork and Jason G. Su. Integrating LIDAR data and multispectral imagery for enhanced classification of rangeland vegetation : A meta analysis. *Remote Sensing of Environment*, 111(1) :11–24, November 2007.
- [11] G. Camps-Valls and L. Bruzzone. Kernel-based methods for hyperspectral image classification. *IEEE Transactions on Geoscience and Remote Sensing*, 43(6) :1351–1362, June 2005.
- [12] Caiyun Zhang. Combining Hyperspectral and Lidar Data for Vegetation Mapping in the Florida Everglades. *Photogrammetric Engineering & Remote Sensing*, 80(8) :733–743, August 2014.
- [13] L. M. Bruce, C. H. Koger, and Jiang Li. Dimensionality reduction of hyperspectral data using discrete wavelet transform feature extraction. *IEEE Transactions on Geoscience and Remote Sensing*, 40(10) :2331–2338, October 2002.
- [14] Daniel Schlöpfer, Jan Biesemans, Andreas Hueni, and Koen Meuleman. Evaluation of the atmospheric correction procedure for the APEX level 2/3 processor. volume 7107, pages 710709–710709–12, 2008.
- [15] J. F. de Haan, J. W. Hovenier, J. M. M. Kokke, and H. T. C. van Stokkom. Removal of atmospheric influences on satellite-borne imagery : A radiative transfer approach. *Remote Sensing of Environment*, 37(1) :1–21, July 1991.

- [16] LASer (LAS) File Format Exchange Activities – ASPRS.
- [17] Centre de compétence en sylviculture | Fachstelle Waldbau.
- [18] WSL > Recherche.
- [19] Kevin P. Murphy. *Machine Learning : A Probabilistic Perspective*. MIT Press, August 2012. Google-Books-ID : NZP6AQAAQBAJ.
- [20] Andrew Ng. CS 229 : Machine Learning (Course handouts).
- [21] F. Pedregosa, G. Varoquaux, A. Gramfort, V. Michel, B. Thirion, O. Grisel, M. Blondel, P. Prettenhofer, R. Weiss, V. Dubourg, J. Vanderplas, A. Passos, D. Cournapeau, M. Brucher, M. Perrot, and E. Duchesnay. Scikit-learn : Machine learning in Python. *Journal of Machine Learning Research*, 12 :2825–2830, 2011.
- [22] Patrick H. Winston. Lecture 16 : Learning : Support Vector Machines | Lecture Videos | Artificial Intelligence | Electrical Engineering and Computer Science | MIT OpenCourseWare.
- [23] Abu-Mostafa Y.S. Learning From Data - Online Course (MOOC), May 2012.
- [24] Xue Li and Shuliang Wang. *Advanced Data Mining and Applications : First International Conference, ADMA 2005, Wuhan, China, July 22-24, 2005, Proceedings*. Springer Science & Business Media, July 2005. Google-Books-ID : tsAkikUb6n0C.





## 6 ANNEXE

TABLE 18 – Indices spectraux

| Nom (anglais)                                    | Abréviation         | Longueurs d'onde [nm] | Formule                                                              |
|--------------------------------------------------|---------------------|-----------------------|----------------------------------------------------------------------|
| Custom ratio                                     | SR Custom           | 780, 860              | $r860 / r780$                                                        |
| Cellulose Absorption Index                       | CAI                 | 2000, 2100, 2200      | $0.5 * (r2000 - r2200) / r2100$                                      |
| Enhanced Vegetation Index                        | EVI                 | 470, 660, 900         | $2.5 * (r900 - r660) / (r900 + 6 * r660 - 7.5 * r470 + 1)$           |
| Green Normalized Difference Vegetation Index     | GNDVI               | 555, 900              | $(r900 - r555) / (r900 + r555)$                                      |
| Simple Ratio (800 nm / 670 nm)                   | SR                  | 670, 800              | $r800 / r670$                                                        |
| Ratio Vegetation Index                           | (RVI) NIR / R ratio | r660, r900            | $r900 / r660$                                                        |
| Transformed Vegetation Index                     | TVI                 | r660, r900            | $\sqrt{((r900 - r660) / (r900 + r660) + 0.5)}$                       |
| Difference Vegetation Index                      | DVI                 | r660, r900            | $r900 - r660$                                                        |
| Normalized Difference Vegetation Index           | NDVI1               | 660, 900              | $(r900 - r660) / (r900 + r660)$                                      |
| Normalized Difference Vegetation Index           | NDVI2               | 670, 800              | $(r800 - r670) / (r800 + r670)$                                      |
| Normalized Difference Vegetation Index           | NDVI3               | 705, 750              | $(r750 - r705) / (r750 + r705)$                                      |
| Wide Dynamic Range Vegetation Index              | WDRVI               | r660, r900            | $\alpha = 2 * \text{mean}(r900) / \text{max}(r660)$                  |
| Green Vegetation Index                           | GVI                 | 553, 682              | $(\alpha * r900 - r660) / (\alpha * r900 + r660)$                    |
| Greenness Index                                  | GI                  | 554, 677              | $(r682 - r553) / (r682 + r553)$                                      |
| Modified Chlorophyll Absorption Ratio Index      | MCARI1              | 550, 670, 700         | $r554 / r677$                                                        |
| Modified Chlorophyll Absorption Ratio Index      | MCARI2              | 550, 670, 800         | $((r700 - r670) - 0.2 * (r700 - r550)) * (r700 / r670)$              |
| Modified Normalized Difference Vegetation Index  | mNDVI1              | 445, 680, 800         | $1.2 * (2.5 * (r800 - r670) - 1.3 * (r800 - r550))$                  |
| Modified Normalized Difference Vegetation Index  | mNDVI2              | 445, 705, 750         | $(r800 - r680) / (r800 + r680 - 2 * r445)$                           |
| Improved Soil Adjusted Vegetation Index          | MSAVI               | 670, 800              | $(r750 - r705) / (r750 + r705 - 2 * r445)$                           |
| Soil Adjusted Vegetation Index                   | SAVI                | 900, 660              | $0.5 * (2 * r800 + 1 - \sqrt{(2 * r800 + 1)^2 - 8 * (r800 - r670)})$ |
| Transformed Soil Adjusted Vegetation Index       | TSAVI               | 900, 660              | $(r900 - r660) / (r900 + r660 + 0.5) + 1.5$                          |
| Perpendicular Vegetation Index                   | PVI                 | 900, 660, a, b        | a, b tel que $r900 = a * r660 + b$                                   |
| Atmospherically Resistant Vegetation Index       | ARVI                | 660, 450              | $a * (r900 - a * r660 - b) / (r660 + r900 - ab + 0.008 * (1 + a^2))$ |
| Soil and Atmospherically Resistant Vegetation I. | SARVI               | 900, rb               | $(r900 - a * r660 - b) / (\sqrt{a^2 + 1})$                           |
| Aerosol-Free Vegetation Index                    | AFVI                | 900, 2100             | $rb = r660 - \gamma * (r450 - r660)$                                 |
| Modified Simple Ratio                            | mSR1                | 445, 680, 800         | $(r900 - rb) / (r900 + rb)$                                          |
| Modified Simple Ratio                            | mSR2                | 445, 705, 750         | $1.3 * (r900 - rb) / (r900 + rb + 0.3)$                              |
| MERIS Terrestrial Chlorophyll index              | MTCI                | 681, 709, 754         | $(r900 - 0.5 * r2100) / (r900 + 0.5 * r2100)$                        |
| modified Triangular Vegetation Index             | mTVI                | 550, 670, 800         | $(r800 - r445) / (r680 - r445)$                                      |
| Optimized Soil-Adjusted Vegetation Index         | OSAVI               | 670, 800              | $(r750 - r445) / (r705 - r445)$                                      |
|                                                  |                     |                       | $(r754 - r709) / (r709 - r681)$                                      |
|                                                  |                     |                       | $1.2 * (1.2 * (r800 - r550) - 2.5 * (r670 - r550))$                  |
|                                                  |                     |                       | $1.16 * (r800 - r670) / (r800 + r670 + 0.16)$                        |

**TABLE 19** – Indices spectraux

| Nom (anglais)                                             | Abréviation | Longueurs d'onde [nm] | Formule                                                                 |
|-----------------------------------------------------------|-------------|-----------------------|-------------------------------------------------------------------------|
| Renormalized Difference Vegetation Index                  | RDVI        | 670, 800              | $(r_{800} - r_{670}) / \sqrt{r_{800} + r_{670}}$                        |
| Red Edge Inflection Point                                 | REIP        | 670, 700, 740, 780    | $r_{700} + 40((r_{670} + r_{780}) / 2 - r_{700}) / (r_{740} - r_{700})$ |
| Structure Insensitive Pigment Index                       | SIP11       | 450, 650, 800         | $(r_{800} - r_{450}) / (r_{800} - r_{650})$                             |
| Structure Insensitive Pigment Index                       | SIP12       | 440, 680, 800         | $(r_{800} - r_{440}) / (r_{800} - r_{680})$                             |
| Leaf Water Index                                          | LWI         | 1300, 1450            | $r_{1300} / r_{1450}$                                                   |
| Normalized Difference Water Index (1240 nm)               | NDWI 1240   | 980, 1240             | $(r_{980} - r_{1240}) / (r_{980} + r_{1240})$                           |
| Normalized Difference Water Index (1240 nm)               | NDWI 1640   | 858, 1640             | $(r_{858} - r_{1640}) / (r_{858} + r_{1640})$                           |
| Pigment Specific Normalized Difference - chl <sub>a</sub> | PSNDA       | 680, 800              | $(r_{800} - r_{680}) / (r_{800} + r_{680})$                             |
| Pigment Specific Simple Ratio - chl <sub>a</sub>          | PSSRa       | 680, 800              | $r_{800} / r_{680}$                                                     |
| Photochemical reflectance Index                           | PRI         | 531, 570              | $(r_{570} - r_{531}) / (r_{570} + r_{531})$                             |
| Narrowband Red Edge Normalised Difference Veget...        | RENDVI      | 705, 750              | $(r_{750} - r_{705}) / (r_{750} + r_{705})$                             |
| Water Band Index                                          | WBI         | 900, 970              | $r_{900} / r_{970}$                                                     |
| Anthocyanin reflectance Index                             | ARI         | 550, 700              | $(1 / r_{550}) - (1 - r_{700})$                                         |
| Blue Green Pigment Index                                  | BGI         | 450, 550              | $r_{450} / r_{550}$                                                     |
| Blue Red Pigment Index                                    | BRJ         | 450, 690              | $r_{450} / r_{690}$                                                     |
| Carotenoid reflectance Index                              | CRI1        | 510, 550              | $(1 / r_{510}) - (1 / r_{550})$                                         |
| Carotenoid reflectance Index                              | CRI2        | 510, 700              | $(1 / r_{510}) - (1 / r_{700})$                                         |
| Red / Green Index                                         | RGI2        | 550, 690              | $r_{690} / r_{550}$                                                     |
| Curvature Index                                           | CI          | 675, 683, 690         | $r_{675} * r_{690} / (r_{683}^2)$                                       |
| Derivative Index                                          | DI          | 706, 730              | $\text{argmax}(\delta r / \delta \lambda)$                              |
| Red-Edge Position                                         | REP         | [690 : 740]           | $\text{max}(\delta r / \delta \lambda)$                                 |
| Red-Edge                                                  | RE          | [690 : 740]           |                                                                         |
|                                                           | LIC         | 440, 690              | $r_{440} / r_{690}$                                                     |
| Normalized Pigment Chlorophyll index                      | NPCI        | 430, 680              | $(r_{680} - r_{430}) / (r_{680} + r_{430})$                             |
| Normalized Phaeophytinization Index                       | NPQI        | 415, 435              | $(r_{415} - r_{435}) / (r_{415} + r_{435})$                             |
| Photochemical reflectance Index                           | PRI1        | 531, 570              | $(r_{531} - r_{570}) / (r_{531} + r_{570})$                             |
| Photochemical reflectance Index                           | PRI2        | 539, 570              | $(r_{570} - r_{539}) / (r_{570} + r_{539})$                             |
| Plant Senescence reflectance Index                        | PSRI        | 500, 680, 750         | $(r_{680} - r_{500}) / r_{750}$                                         |

**TABLE 20** – Inventaire de bandes hyperspectrales, longueur d'onde  $\lambda$  [ $\mu m$ ]

| (a)   |           | (b)   |           | (c)   |           | (d)   |           |
|-------|-----------|-------|-----------|-------|-----------|-------|-----------|
| Bande | $\lambda$ | Bande | $\lambda$ | Bande | $\lambda$ | Bande | $\lambda$ |
| 1     | 0.41261   | 31    | 0.62015   | 61    | 0.7118    | 91    | 0.85458   |
| 2     | 0.42619   | 32    | 0.62265   | 62    | 0.71557   | 92    | 0.86072   |
| 3     | 0.4386    | 33    | 0.62518   | 63    | 0.7194    | 93    | 0.86693   |
| 4     | 0.45018   | 34    | 0.62776   | 64    | 0.72328   | 94    | 0.87318   |
| 5     | 0.46092   | 35    | 0.63037   | 65    | 0.72722   | 95    | 0.87949   |
| 6     | 0.47052   | 36    | 0.63301   | 66    | 0.73123   | 96    | 0.88588   |
| 7     | 0.47982   | 37    | 0.63569   | 67    | 0.73529   | 97    | 0.89238   |
| 8     | 0.48932   | 38    | 0.63841   | 68    | 0.73941   | 98    | 0.89901   |
| 9     | 0.49882   | 39    | 0.64116   | 69    | 0.74359   | 99    | 0.90578   |
| 10    | 0.50818   | 40    | 0.64395   | 70    | 0.74784   | 100   | 0.91273   |
| 11    | 0.51693   | 41    | 0.64678   | 71    | 0.75214   | 101   | 0.91987   |
| 12    | 0.5248    | 42    | 0.64963   | 72    | 0.75651   | 102   | 0.92719   |
| 13    | 0.53227   | 43    | 0.65252   | 73    | 0.76094   | 103   | 0.93465   |
| 14    | 0.53927   | 44    | 0.65545   | 74    | 0.76543   | 104   | 0.94219   |
| 15    | 0.54584   | 45    | 0.65841   | 75    | 0.77001   | 105   | 0.94974   |
| 16    | 0.55182   | 46    | 0.66139   | 76    | 0.77466   | 106   | 0.95768   |
| 17    | 0.55709   | 47    | 0.66442   | 77    | 0.77941   | 107   | 0.96602   |
| 18    | 0.56249   | 48    | 0.66748   | 78    | 0.78424   | 108   | 0.97445   |
| 19    | 0.56805   | 49    | 0.67058   | 79    | 0.78916   | 109   | 0.98297   |
| 20    | 0.57284   | 50    | 0.67374   | 80    | 0.79417   | 110   | 0.99156   |
| 21    | 0.57679   | 51    | 0.67694   | 81    | 0.79926   | 111   | 1.0002    |
| 22    | 0.58084   | 52    | 0.6802    | 82    | 0.80443   | 112   | 1.0089    |
| 23    | 0.58498   | 53    | 0.6835    | 83    | 0.80968   | 113   | 1.0177    |
| 24    | 0.58922   | 54    | 0.68686   | 84    | 0.81501   | 114   | 1.0265    |
| 25    | 0.59354   | 55    | 0.69027   | 85    | 0.8204    | 115   | 1.0354    |
| 26    | 0.59796   | 56    | 0.69373   | 86    | 0.82585   | 116   | 1.0443    |
| 27    | 0.60246   | 57    | 0.69724   | 87    | 0.83138   | 117   | 1.0532    |
| 28    | 0.60704   | 58    | 0.7008    | 88    | 0.83699   | 118   | 1.0621    |
| 29    | 0.61171   | 59    | 0.70441   | 89    | 0.84272   | 119   | 1.0712    |
| 30    | 0.61648   | 60    | 0.70808   | 90    | 0.84857   | 120   | 1.0803    |

**TABLE 21** – Inventaire de bandes hyperspectrales, longueur d'onde  $\lambda$  [ $\mu m$ ] (Suite)

| (a)   |           | (b)   |           | (c)   |           | (d)   |           | (e)   |           |
|-------|-----------|-------|-----------|-------|-----------|-------|-----------|-------|-----------|
| Bande | $\lambda$ | Bande | $\lambda$ | Bande | $\lambda$ | Bande | $\lambda$ | Bande | $\lambda$ |
| 121   | 1.0895    | 151   | 1.3786    | 181   | 1.6573    | 211   | 1.9102    | 241   | 2.1367    |
| 122   | 1.0988    | 152   | 1.3884    | 182   | 1.6662    | 212   | 1.9181    | 242   | 2.1439    |
| 123   | 1.1082    | 153   | 1.3981    | 183   | 1.675     | 213   | 1.9259    | 243   | 2.151     |
| 124   | 1.1176    | 154   | 1.4079    | 184   | 1.6838    | 214   | 1.9337    | 244   | 2.1581    |
| 125   | 1.127     | 155   | 1.4176    | 185   | 1.6927    | 215   | 1.9415    | 245   | 2.1652    |
| 126   | 1.1364    | 156   | 1.4273    | 186   | 1.7015    | 216   | 1.9493    | 246   | 2.1721    |
| 127   | 1.1458    | 157   | 1.4369    | 187   | 1.7103    | 217   | 1.9571    | 247   | 2.179     |
| 128   | 1.1553    | 158   | 1.4465    | 188   | 1.7191    | 218   | 1.9649    | 248   | 2.186     |
| 129   | 1.1649    | 159   | 1.4561    | 189   | 1.7278    | 219   | 1.9727    | 249   | 2.193     |
| 130   | 1.1745    | 160   | 1.4655    | 190   | 1.7364    | 220   | 1.9805    | 250   | 2.2001    |
| 131   | 1.1842    | 161   | 1.4749    | 191   | 1.745     | 221   | 1.9882    | 251   | 2.2073    |
| 132   | 1.194     | 162   | 1.4842    | 192   | 1.7535    | 222   | 1.9959    | 252   | 2.2143    |
| 133   | 1.2038    | 163   | 1.4935    | 193   | 1.7619    | 223   | 2.0035    | 253   | 2.2213    |
| 134   | 1.2136    | 164   | 1.5027    | 194   | 1.7703    | 224   | 2.0112    | 254   | 2.2282    |
| 135   | 1.2233    | 165   | 1.5119    | 195   | 1.7787    | 225   | 2.0188    | 255   | 2.2351    |
| 136   | 1.2329    | 166   | 1.5211    | 196   | 1.7871    | 226   | 2.0265    | 256   | 2.242     |
| 137   | 1.2426    | 167   | 1.5303    | 197   | 1.7954    | 227   | 2.0341    | 257   | 2.2489    |
| 138   | 1.2522    | 168   | 1.5395    | 198   | 1.8038    | 228   | 2.0416    | 258   | 2.2558    |
| 139   | 1.2619    | 169   | 1.5488    | 199   | 1.8121    | 229   | 2.049     | 259   | 2.2626    |
| 140   | 1.2716    | 170   | 1.558     | 200   | 1.8204    | 230   | 2.0564    | 260   | 2.2693    |
| 141   | 1.2813    | 171   | 1.5672    | 201   | 1.8288    | 231   | 2.0638    | 261   | 2.276     |
| 142   | 1.291     | 172   | 1.5763    | 202   | 1.837     | 232   | 2.0712    | 262   | 2.2827    |
| 143   | 1.3009    | 173   | 1.5854    | 203   | 1.8453    | 233   | 2.0786    | 263   | 2.2894    |
| 144   | 1.3107    | 174   | 1.5945    | 204   | 1.8534    | 234   | 2.086     | 264   | 2.296     |
| 145   | 1.3203    | 175   | 1.6036    | 205   | 1.8615    | 235   | 2.0933    | 265   | 2.3027    |
| 146   | 1.3299    | 176   | 1.6127    | 206   | 1.8696    | 236   | 2.1006    | 266   | 2.3093    |
| 147   | 1.3395    | 177   | 1.6217    | 207   | 1.8776    | 237   | 2.1078    | 267   | 2.3159    |
| 148   | 1.3492    | 178   | 1.6307    | 208   | 1.8857    | 238   | 2.115     | 268   | 2.3225    |
| 149   | 1.359     | 179   | 1.6396    | 209   | 1.8939    | 239   | 2.1223    | 269   | 2.3291    |
| 150   | 1.3688    | 180   | 1.6485    | 210   | 1.9021    | 240   | 2.1295    | 270   | 2.3357    |

**TABLE 22** – Inventaire de bandes hyperspectrales, longueur d’onde  $\lambda$  [ $\mu m$ ] (Suite et fin)

| Bande | $\lambda$ |
|-------|-----------|
| 271   | 2.3422    |
| 272   | 2.3487    |
| 273   | 2.3552    |
| 274   | 2.3617    |
| 275   | 2.3681    |
| 276   | 2.3745    |
| 277   | 2.3808    |
| 278   | 2.3871    |
| 279   | 2.3935    |
| 280   | 2.3999    |
| 281   | 2.4062    |
| 282   | 2.4126    |
| 283   | 2.4189    |
| 284   | 2.4251    |
| 285   | 2.4313    |